

Отчет о проекте Mini QSAR для прогнозирования молекулярной растворимости

Mini QSAR Project Report for Molecular Solubility Prediction

1. Обзор проекта / Project Overview

Этот проект представляет собой практический эксперимент в области QSAR (Quantitative Structure-Activity Relationship) и Machine Learning. Главная цель — обучить вычислительную модель прогнозировать растворимость молекул на основе их химических характеристик.

Химическая молекула → Цифровые дескрипторы → Модель Machine Learning → Прогноз растворимости

Проект не направлен на создание нового алгоритма, а является практическим применением апробированного подхода для понимания всего цикла: от сырых химических данных до готовой прогностической модели.

2. Почему именно растворимость / Why Solubility

Растворимость — ключевое физико-химическое свойство, критически важное в фармацевтике, биотехнологии и химии. Вместо работы со сложной геометрической формой молекулы, её структура описывается набором числовых параметров (дескрипторов), которые затем используются алгоритмами машинного обучения для выявления закономерностей.

3. Источник данных / Data Source

В работе использован классический датасет Delaney ESOL (Water Solubility Dataset).

Параметр / Parameter	Значение / Description
Общее количество соединений (Total Compounds)	1128
Формат структуры (Structure Representation)	SMILES для каждого соединения
Целевая переменная (Target Variable)	Экспериментальная логарифмическая растворимость (Measured log solubility)
Тип данных (Data Authenticity)	Реальные экспериментальные данные

4. Программное обеспечение и инструменты / Software and Tools

Инструмент / Tool	Назначение / Purpose
Google Colab	Облачная среда для выполнения Python-кода без высоких требований к локальному ПК.
Python	Основной язык программирования проекта.
Pandas	Загрузка, очистка и табличная структура данных.
RDKit	Хемоинформатическая библиотека для чтения SMILES и генерации молекулярных дескрипторов.
Scikit-learn	Построение, обучение и оценка моделей Machine Learning.

5. Что такое SMILES / What is SMILES

SMILES (Simplified Molecular Input Line Entry System) — текстовая система записи химических структур. Вместо передачи графического изображения компьютер получает строку символов:

SMILES → RDKit → Молекулярный объект для анализа

6. Извлечение молекулярных дескрипторов / Molecular Feature Extraction

С помощью библиотеки RDKit для каждого соединения было рассчитано 7 ключевых молекулярных дескрипторов:

№	Дескриптор / Descriptor	Описание / Description
1	Molecular Weight	Молекулярная масса соединения.
2	LogP	Коэффициент распределения октанол/вода (липофильность).
3	Hydrogen Bond Donors	Количество доноров водородных связей.
4	Hydrogen Bond Acceptors	Количество акцепторов водородных связей.
5	TPSA	Топологическая площадь полярной поверхности.
6	Ring Count	Количество колец в молекуле.
7	Rotatable Bonds	Количество вращающихся связей.

7. Преобразование задачи в Machine Learning / Problem Formulation

Структура данных была разделена на входные признаки (X) и целевую переменную (Y):

- **X (Features):** Molecular Weight, LogP, H-Bond Donors, H-Bond Acceptors, TPSA, Ring Count, Rotatable Bonds.
- **Y (Target):** Measured log solubility.

Главный вопрос: Способна ли модель Machine Learning выявить математическую зависимость между этими 7 дескрипторами и растворимостью?

8. Разделение данных / Data Splitting

Для предотвращения переобучения и корректного тестирования выборка была разделена в соотношении 80/20:

Подвыборка / Subset	Доля / Percentage	Количество соединений / Count
Обучающая (Training Set)	80%	902
Тестовая (Testing Set)	20%	226

9. Первая модель: Linear Regression / First Model: Linear Regression

В качестве базового уровня (baseline) использована модель Linear Regression, выстраивающая линейную комбинацию признаков. Это позволило оценить простейшую зависимость перед переходом к нелинейным алгоритмам.

10 & 11. Вторая модель: Random Forest / Second Model: Random Forest

Для учета сложных нелинейных взаимодействий применен ансамблевый алгоритм Random Forest Regressor с количеством деревьев `n_estimators = 300`.

12. Сравнение результатов моделей / Model Results & Comparison

Ниже приведены итоговые метрики моделей, полученные на независимой тестовой выборке (226 соединений):

Метрика / Metric	Linear Regression	Random Forest	Улучшение / Advantage
MAE (Mean Absolute Error)	0.811	0.560	Ниже у Random Forest (лучше)
RMSE (Root Mean Squared Error)	1.069	0.810	Ниже у Random Forest (лучше)
R² (Coefficient of Determination)	0.758 (75.8%)	0.861 (86.1%)	Выше у Random Forest (лучше)

Модель Random Forest объясняет 86.1% дисперсии показателей растворимости на тестовых данных, показав существенное превосходство над линейной регрессией.

13 & 14. Оценка и интерпретация метрик / Model Evaluation

Метрика / Metric	Физический смысл / Description
MAE	Средний абсолютный модуль отклонения предсказанного значения от фактического.
RMSE	Среднеквадратичная ошибка, штрафующая за крупные единичные промахи.
R²	Доля дисперсии целевой переменной, объясняемая моделью (чем ближе к 1, тем лучше).

15. Визуализация и анализ / Visualizations and Analysis

В ходе работы построены следующие графики:

- Сопоставление экспериментальных (Measured) и предсказанных (Predicted) значений.
- Анализ важности признаков (Feature Importance) в Random Forest для определения наиболее влиятельных дескрипторов.

16. Полный конвейер проекта / Project Workflow Pipeline

Экспериментальные данные → SMILES → RDKit → Descriptors (X) → Train/Test Split (80/20) → Linear Regression & Random Forest → Predictions → Evaluation (MAE, RMSE, R²)

17. Новизна проекта / What is New

Проект не претендует на создание новой теории или нового алгоритма. Практическая ценность заключается в самостоятельной сборке сквозного решения (End-to-End Pipeline) от сырых химических данных до валидации машинного обучения.

18. Ошибки в процессе работы / Technical Errors Encountered

В ходе разработки в Google Colab возникали рабочие ошибки (например, случайный запуск ячейки с текстовым анализом в режиме Code, вызвавший SyntaxError). Все ошибки были проанализированы и устранены, что стало частью практического обучения.

19. Ограничения проекта / Project Limitations

№	Ограничение / Limitation
1	Использование только одного датасета (Delaney ESOL).
2	Ограниченный набор из 7 дескрипторов.
3	Случайное разделение данных (без применения Scaffold Split).
4	Отсутствие глубокой кросс-валидации и внешней валидационной выборки.
5	Отсутствие оценки области применимости (Applicability Domain).

20. Чему мы научились / Lessons Learned

Освоен полный цикл решения прикладной хемоинформатической задачи: формулировка проблемы → подготовка данных → выбор моделей → обучение → тестирование → интерпретация.

21. Связь с растительной биотехнологией / Relevance to Plant Biotechnology

Хотя данный проект выполнен на химических данных, методологический подход полностью применим к растительной биотехнологии (Genomics, Transcriptomics, Phenomics, Plant Metabolomics). Главный принцип — перевод биологических характеристик в цифровой формат и построение прогнозов на основе данных.

22. Заключение / Conclusion

Проект Mini QSAR продемонстрировал работоспособность подхода: использование RDKit и Random Forest позволило достичь R² = 0.861 при прогнозировании растворимости молекул.

Обращение автора / Note from the Author:

Спасибо за внимание и время, уделенное рассмотрению моего проекта. Этот проект был построен с большим увлечением и стал попыткой принять вызов ограниченности ресурсов за счет максимального использования всех доступных (شغف) инструментов.

Я искренне надеюсь, что этот скромный труд продемонстрирует мое стремление к учебе и исследовательской работе. Для меня было бы огромной честью получить возможность продолжать обучение и академическое развитие в российских образовательных и научных учреждениях, где я смогу приложить еще больше усилий и энергии.

Приношу свои извинения за возможные языковые или орфографические неточности в переводе.